

Implémentation from scratch d'un MLP et moteur d'autodifférenciation appliqués à MNIST

Jianye Shi, Hao Qian, Xiang Bian, Abdenmour Boulmis

M1 CHPS – Université Paris-Saclay
UVSQ 2025/2026

5 janvier 2026

Plan de la présentation

- 1 Introduction et Contexte
- 2 Fondements théoriques
- 3 Implémentation
- 4 Expérimentations
- 5 Organisation et Conclusion

Déroulement

- Contexte et problématique (5 min)
- Architecture et implémentation (7 min)
- Résultats expérimentaux (7 min)
- Conclusion et perspectives (1 min)

Objectifs

- Implémenter **from scratch** un réseau de neurones (MLP) en C++
- Développer un moteur de différenciation automatique
- Appliquer au dataset MNIST (reconnaissance de chiffres manuscrits)
- Double focus : **Machine Learning + High Performance Computing**

Aspect ML

- Rétropropagation
- Optimisation (SGD)
- Convergence

Aspect HPC

- Optimisation bas niveau
- Parallélisme (OpenMP)
- BLAS, vectorisation

Le problème MNIST

- **Dataset classique** de classification
- Images 28×28 pixels (784 features)
- 10 classes (chiffres 0-9)
- 60,000 images d'entraînement
- 10,000 images de test

[Image MNIST]

Objectif : $\sim 98\%$ de précision

Notre approche : MLP simple mais complet

- Architecture : $784 \rightarrow 128 \rightarrow 10$
- Activation ReLU
- Loss CrossEntropy

Architecture du MLP




Figure – Structure hiérarchique du MLP

Propagation avant (Forward)

Entrée : $X \in \mathbb{R}^{N \times 784}$

Couche cachée :

$$H = \sigma(XW_1 + b_1)$$

Sortie :

$$Y = \text{softmax}(HW_2 + b_2)$$

Calcul par mini-batch

- Vectorisation des opérations
- Exploitation du parallélisme
- N exemples simultanément

Principe du DAG (Directed Acyclic Graph)

- Chaque opération = un nœud
- Stockage des valeurs intermédiaires
- Calcul automatique des gradients

Règle de la chaîne

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial x}$$

Backward pass

- Tri topologique du graphe
- Propagation des gradients
- Mise à jour des paramètres

Exemple simple

$$z = x \cdot w$$

$$y = z + b$$

$$L = y^2$$

Gradients :

$$\frac{\partial L}{\partial y} = 2y$$

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial y}$$

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial z} \cdot x$$

Architecture logicielle

Haut niveau

main.cpp – Point d'entrée CLI

Trainer – Boucle forward → backward → update

Loss + Optimizer – CrossEntropy, SGD

MLPNetwork – Assemblage multi-couches

LinearLayer + Activation – Composants réseau

Node + MathOps – Moteur d'autodifférenciation

Bas niveau

Matrix/Tensor – Opérations mathématiques bas niveau

Choix de conception

- Stockage contigu : `std::vector<double>`
- Optimisation de la localité cache
- Support de la vectorisation (SIMD)

Implémentations `matmul`

- Naïve (*ijk*) : pédagogique
- Réordonnée (*ikj*) : cache-friendly
- Bloquée : optimisation cache
- OpenMP : parallélisation
- BLAS : référence optimisée

Sélection runtime

Initialisation des poids

- **He** : pour ReLU
 $\text{Var}(W) = 2/n_{in}$
- **Xavier** : pour Sigmoid/Tanh
 $\text{Var}(W) = 1/n_{in}$
- **Manual** : $[-0.1, 0.1]$

Reproductibilité

Graine contrôlée (`-seed`)

Moteur d'autodiff : Node et MathOps

Implémentation via Lambdas C++

- `std::shared_ptr<Node>` : gestion mémoire automatique
- Capture du contexte par closures
- Pas de classes dédiées par opération

```
// La puissance des Lambdas pour l'Autodiff (math_ops.cpp)
// Capture du contexte {a, b} par closure
node->setBackwardFn([a, b](const Matrix& grad) {

    // Application directe de la Chain Rule
    a->addGrad(grad.mul(b->value())); //  $dL/da = grad * b$ 
    b->addGrad(grad.mul(a->value())); //  $dL/db = grad * a$ 

});
```

Avantages

- Tri topologique (DFS)

Performance

- Sans récursion profonde

Construction du modèle MLPNetwork

Le réseau est construit par composition modulaire avec support multi-couches :

```
// Architecture flexible (network.cpp)
MLPNetwork MLPNetwork::createMultiHidden(
    int input_dim, const std::vector<int>& hidden_dims,
    int output_dim, const std::string& activation_name,
    const std::string& init_name, unsigned int seed
) {
    MLPNetwork net;
    int prev = input_dim;

    // Couches cachees : prev -> h + activation
    for (int h : hidden_dims) {
        net.addLayer(
            makeLinear(prev, h, init_name, seed),
            makeActivation(activation_name)
        );
        prev = h;
    }

    // Couche de sortie : logits, sans activation
    net.addLayer(makeLinear(prev, output_dim, init_name, seed),
```

Pipeline d'entraînement

Modules principaux

- `LinearLayer` : $y = xW + b$
- `ActivationFunction`
ReLU, Sigmoid, Tanh
- `LossFunction`
MSE, CrossEntropy
- `Optimizer` : SGD
- `DataLoader` : mini-batch

Boucle d'entraînement

- 1 Charger mini-batch (X, Y)
- 2 **Forward** : $\hat{Y} = \text{Model}(X)$
- 3 **Loss** : $L = \text{Loss}(\hat{Y}, Y)$
- 4 **Backward** : calcul gradients
- 5 **Update** : $W \leftarrow W - \eta \nabla W$

```
// Implementation SGD (optimizer.cpp)
void SGDOptimizer::step() {
    for (auto& p : parameters_) {
        Matrix& val = const_cast<Matrix&>(p->value());
        const Matrix& grad = p->grad();
        for(size_t i=0; i<val.data.size(); ++i) {
            val.data[i] -= lr_ * grad.data[i]; // W = W - eta * grad
        }
    }
}
```

Matériel

- AMD Ryzen 9 8940HX
- 16 cœurs / 32 threads
- 30 GiB RAM
- Cache L3 : 64 MiB

Logiciel

- Fedora Linux 42
- GCC 15.2.1
- Flags : `-O3 -march=native`


Protocole rigoureux

- **Fréquence verrouillée** : 4.0 GHz
- **Affinité CPU** : taskset
- **Warm-up** : 5 itérations
- **Graine fixée** : reproductibilité

Objectif


Mesures fiables et reproductibles pour comparer les optimisations

Passage à l'échelle (Thread Scaling)



d'exécution vs threads

Temps




threads

Speedup vs

- **64×64** : surcoût > gain au-delà de 8 threads
- **2048×2048** : limité par bande passante mémoire
- **Optimum** : 8 threads = cœurs physiques

Hiérarchie des performances



Comparaison des implémentations matmul (matrices 2048×2048)


Version	Temps (ms)	Speedup	Technique
Naïf (<i>ijk</i>)	~3000	1×	Baseline
Réordonné (<i>ikj</i>)	~800	3.75×	Localité cache
OpenMP (8T)	~150	20×	Parallélisation
BLAS	~15	200×	Vect. + SIMD

Avant optimisation (Naïf)

- matmul : **96%**
- Compute-bound
- Temps/époque : 13.27s

Après optimisation (BLAS)

- matmul : **<1%**
- I/O données : 43%
- Allocations : 29%
- Temps/époque : 1.74s





Répartition temps E2E

Speedup Global

7.6×

Limité par I/O (Amdahl)

Convergence : premiers résultats



Batch=64, Hidden=128, ReLU, 20 époques)

Loss et Accuracy (LR=0.01,

Précision finale

~98.2%

Convergence
Rapide et stable

Généralisation
Écart train/val modéré

Impact du Learning Rate





Figure – Influence du taux d'apprentissage (10 époques, 3 graines)

- LR = 0.001 : Trop lent ($\sim 97.2\%$)
- LR $\in [0.005, 0.01]$: **Zone optimale** ($\sim 98.0\%$)
- LR = 0.025 : **Divergence** ($\sim 32.1\%$, variance élevée)

Impact du Batch Size

Batch Size Experiment Results (20 Epochs)



Influence de la taille de batch (20 époques, LR=0.01, 3 graines, Hidden=128)


$B \in \{16, 32\}$
Meilleur accuracy
Plus lent

$B = 64$
Compromis optimal
Précision + vitesse

$B \in \{128, 256\}$
Dégradation
LR fixe inadapté


Impact de la taille cachée et de l'activation

Hidden Size Experiment Results (20 Epochs)



Taille de couche
cachée

Activation Function Experiment Results (20 Epochs)



Fonctions d'activation

Observations

- H=64 : Sous-apprentissage
- **H=128 : Optimal**
- H=256 : Gain marginal

Résultats

- **ReLU : Meilleur**
- Tanh/Sigmoid : OK avec Xavier

Configuration finale

Learning Rate : **0.01**
Batch Size : **64**
Hidden Size : **128**
Activation : **ReLU**
Initialisation : **He**

Précision validation : ~98.2%

- Validation par Grid Search (3 graines par configuration)

Organisation du projet

Répartition des tâches

- **État de l'art** : Jianye, Hao, Xiang (collectif)
- **Conception** : Jianye (documentation, UML)
- **Prototype MLP** : Abdenmour (tenseurs, couches, activations)
- **Moteur autodiff** : Hao + Xiang (graphe, opérations)
- **Intégration** : Jianye (pipeline complet, MNIST)
- **Entraînement** : Xiang (boucle), Jianye + Hao (optimizer, loss)
- **Optimisation HPC** : Jianye (profiling, benchmarks, Grid Search)
- **Rapport** : Collectif

Méthodologie

Développement incrémental avec validation continue à chaque étape

Réalisations

- ✓ Implémentation complète **from scratch** en C++
- ✓ Moteur d'autodiff fonctionnel et élégant (DAG + lambdas)
- ✓ Validation ML : **~98.2%** de précision sur MNIST
- ✓ Optimisation HPC : speedup **200×** sur le noyau de calcul

Enseignements clés

- **Dual challenge** : algorithmique (convergence) + computationnel (performance)
- **Loi d'Amdahl** : après optimisation du calcul, les I/O deviennent le goulot
- **Importance du protocole** : mesures reproductibles essentielles

Extensions ML

- Optimiseurs avancés (Momentum, Adam)
- Régularisation (L2, Dropout)
- Architectures CNN
- Datasets plus complexes

Optimisations HPC

- Support GPU (CUDA)
- Vectorisation explicite (AVX-512)
- Memory pool / arenas

Parallélisme à l'échelle

- Data parallelism (MPI)
- Model parallelism
- Pipeline de données optimisé

Reproductibilité

- Framework de benchmarking
- CI/CD pour validation
- Documentation utilisateur

Projet complet disponible sur [[lien GitHub](#)]

Merci de votre attention !

Questions ?

Implémentation du produit matriciel

```
// Version naive (ijk) - mauvaise localite cache
for (int i = 0; i < m; ++i)
    for (int j = 0; j < p; ++j)
        for (int k = 0; k < n; ++k)
            C(i,j) += A(i,k) * B(k,j);
```

```
// Version reordonnee (ikj) - meilleure localite
for (int i = 0; i < m; ++i)
    for (int k = 0; k < n; ++k)
        for (int j = 0; j < p; ++j)
            C(i,j) += A(i,k) * B(k,j);
```

```
// Version OpenMP
#pragma omp parallel for
for (int i = 0; i < m; ++i)
    for (int k = 0; k < n; ++k)
        for (int j = 0; j < p; ++j)
            C(i,j) += A(i,k) * B(k,j);
```

Exemple de calcul de gradient (LinearLayer)

$$\text{Forward : } Y = XW + b$$

$$\text{Backward : } \frac{\partial L}{\partial X} = \frac{\partial L}{\partial Y} \cdot W^T$$

$$\frac{\partial L}{\partial W} = X^T \cdot \frac{\partial L}{\partial Y}$$

$$\frac{\partial L}{\partial b} = \sum \frac{\partial L}{\partial Y}$$

Implémentation

- Stockage de X pendant le forward
- Calcul des trois gradients lors du backward
- Accumulation dans les nœuds parents